

Análisis de Regresión: Gasto Calórico

Nicolás de Silva Nacenta, Israel Rodríguez Donato, Andrés Manuel Roldán Navarro

29 de mayo de 2026

El objetivo de este proyecto es ajustar una regresión lineal que explique el gasto calórico, así como evaluar cada modelo que se proponga.

1. Análisis descriptivo de datos


1.1. Estadísticos descriptivos

Table 1: Estadísticos descriptivos


	Media	Mediana	Moda	Varianza	Desviacion_Estandar
Calories	90.47	85.00	11.00	4143.61	64.37
Age	41.16	38.00	25.00	257.75	16.05
Height	173.85	174.00	179.00	177.87	13.34
Weight	74.33	73.00	57.00	210.13	14.50
BMI	24.32	24.37	23.72	2.77	1.66
Duration	15.58	17.00	6.00	74.35	8.62
Heart_Rate	95.79	97.00	101.00	99.35	9.97
Body_Temp	39.99	40.30	40.60	0.71	0.85

1.2. Matriz de correlación:

Hombres



Mujeres



Se pueden observar tres grupos de variables correlacionadas entre si para ambos género. Consisten en:

- Grupo 1: *Calories*, *Duration*, *Heart_Rate*, *Body_Temp*
- Grupo 2: *Height*, *Weight*, *BMI*
- Grupo 3: *Age*

Se puede ver que la edad no esta correlacionada con ninguna de las otras variables. Podria no ser significativa para la quema de calorías. La altura, peso e índice de masa corporal son caracateristicas físicas de la persona en cuestión, además el índice de masa corporal es directamente calculada usando las otras dos variables. Por último, la duración, frecuencia cardíaca y temperatura corporal son consecuencia del ejercicio en cuestión lo cual nos lleva a pensar que son los que mas afectan a la quema de calorías.

Analizando las matrices notamos que entre ambos géneros no existe gran diferencia en la correlación lo cual podría explicar que ningun género presenta ventaja sobre el otro a la hora de la quema de calorías.

2. Modelo de Regresión Lineal Simple

2.1. Selección de variable explicativa

Al realizar la rutina de ejercicio, el gasto calorico podría ser explicado por alguna de las siguientes variables numéricas, seleccionadas por tener una alta correlación con el gasto calórico:

- *Duration*: tiene sentido pensar que mientras más tiempo se haya hecho ejercicio, mayo será el gasto calórico.
- *Heart_Rate*: el número de latidos por minuto puede funcionar como una métrica del esfuerzo realizado por el individuo durante la rutina, esperaríamos que mayor esfuerzo, mayor gasto calorico.

- Body_Temp: al igual que el número de latidos, una alta temperatura corporal indicaría un mayor gasto calórico, debido al esfuerzo realizado.

Los modelos propuestos tienen coeficientes estimados estadísticamente significativos, sin embargo, al analizar el ajuste y los residuales, los mejores modelos fueron los basados en duración y frecuencia cardíaca, esto fue respaldado por AIC y BIC, donde el mejor AIC y BIC fue para el modelo basado en duración y el segundo mejor el basado en frecuencia cardíaca, por lo tanto, decidimos descartar el modelo basado en temperatura corporal.

De los modelos basados en duración y frecuencia cardíaca, ninguno cumplió satisfactoriamente los supuestos, particularmente, presentan problemas graves de heterocedasticidad. Al estimar el parámetro λ de Boxcox, para el modelo basado en duración se obtuvo $\lambda = 0.5$ y para el basado en frecuencia cardíaca se obtuvo $\lambda = 0.6$. Por lo tanto, dado que $\lambda = 0.5$ tiene una buena interpretación y fue el obtenido del mejor candidato de variable explicatoria, decimos transformar a las calorías obteniendo su raíz cuadrada (la cual no es la transformación original de boxcox, pero es una combinación lineal de ella).

Una vez aplicada la transformación, comparamos dos modelos: la raíz cuadrada del gasto calórico explicado por la duración de la rutina vs la frecuencia cardíaca. Encontramos que el mejor modelo en términos de AIC, BIC, ajuste y residuales es el modelo basado en duración, por lo que es el modelo seleccionado que explicaremos a continuación.

2.2 Explicación del modelo.

El modelo posee un intercepto estimado de 2.1863 y una $\hat{\beta}_1$ estimada de 0.4216, ambos con p-valor menor a 2×10^{-16} , lo que indica una alta significancia estadística. La interpretación es: al aumentar un minuto en la rutina de ejercicios, la raíz cuadrada del gasto calórico aumenta en 0.42 unidades.

Notemos dos cosas, la primera es que el intercepto cumple la función de dar soporte a la recta, ya que una rutina de 0 minutos no tiene sentido; la segunda, la modelación se transfiere del gasto calórico a la raíz cuadrada del gasto calórico.

2.3 Ajuste del modelo

El coeficiente de determinación es de 0.9518, el ajustado es de 0.9515, significa que la duración explica en un 95% el comportamiento de la raíz cuadrada del gasto calórico, y tiene sentido que no varíen entre sí, ya que el coeficiente de determinación ajustado penaliza por añadir variables, pero al ser un modelo simple, no existe tan penalización.

El error estándar residual estimado es de 0.8204, indicando una desviación estándar de los errores de ± 0.8204 , el residual mínimo posee un valor de -3.08537 y el máximo de 2.75438, con una media de -0.02556, esto significa que los residuales presentan una variación mínima, y el 50% de los errores son cercanos a cero.

2.4 Evaluación de supuestos

Prueba	Supuesto	Estadístico	p-value	Conclusión
Shapiro-Wilk	Normalidad	$W = 0.9862$	0.048	Se rechaza H_0
NCV Score Test	Homocedasticidad	$J^2 = 4.5665$	0.033	Se rechaza H_0
Durbin-Watson	Independencia	$DW = 1.8305$	0.115	No se rechaza H_0
Breusch-Godfrey	Independencia	$LM = 1.1201$	0.290	No se rechaza H_0

El modelo no cumple con el supuesto de normalidad ni con el de homocedasticidad, sin embargo, no es un resultado catastrófico, notemos que, aumentando el margen con $\alpha = 0.01$ el modelo quedaría aprobado. Aún así, no puede ignorarse que, aun aplicando una transformación al gasto calórico, el modelo sigue sin ser homocedástico.

En general, el modelo es bastante bueno, los coeficientes estimados son altamente significativos, el ajuste y los residuales son excelentes y en criterios AIC y BIC es superior frente a otros modelos simples. Que no

haya cumplido el supuesto de homocedasticidad revela que una sola variable no es suficiente para explicar el comportamiento del gasto calórico, o bien, que el comportamiento no puede ser explicado con un modelo clásico de regresión.


2.5. Intervalos de confianza (95 %)

Table 2: Coeficientes e IC - $\sqrt{\text{Calories}} \sim \text{Duration}$


Parámetro	Estimación	Lím_inferior	Lím_superior
(Intercept)	2.1863	1.9496	2.4230
Duration	0.4216	0.4083	0.4349

Table 3: Coeficientes e IC - $\sqrt{\text{Calories}} \sim \text{Heart_Rate}$

Parámetro	Estimación	Lím_inferior	Lím_superior
(Intercept)	-23.8486	-25.9353	-21.7619
Heart_Rate	0.3404	0.3187	0.3620




Raiz Calorias ~ Frecuencia Cardiaca



2.6. Intervalos para respuesta media y predicción


Raíz(Calorías) ~ Duración

Bandas: gris = predicción, azul = confianza de la media



Raíz(Calorías) ~ Duración

Bandas: gris = predicción, azul = confianza de la media



3. Modelo de Regresión Lineal Múltiple

3.1. Selección de variables

Para una selección inicial definimos un modelo utilizando todas las variables. Mediante un stepwise AIC con dirección hacia atrás verificamos que eliminando la variable *Gender* obtenemos un menor AIC que el original. Posiblemente debido a que realmente el género no afecta fuertemente en la correlación del resto de variables como se vio en la matriz de correlación.

3.2. Evaluación de multicolinealidad del modelo

Desde la matriz de correlación obteníamos distintos grupos de variables, lo cual es posible que se presente alta multicolinealidad. Obtenemos los siguientes valores de inflación de la varianza para cada variable.

Table 4: Valores de Inflación de la Varianza (VIF)

	VIF
Age	1.115079
Height	134.082375
Weight	217.577707
BMI	27.728096
Duration	9.691175
Heart_Rate	4.100656
Body_Temp	5.814618

Podemos ver que el modelo tiene multicolinealidad fuerte en las variables *Height*, *Weight* y *BMI*, donde directamente el índice de masa corporal es una relación entre la altura y el peso lo cual explica la alta correlación entre este grupo de variables. Por otro lado, variables como *Duration*, *Heart_Rate* y *Body_Temp* presentan multicolinealidad moderada. Igualmente por la matriz de correlación observamos una correlación fuerte entre este otro grupo de variables. Por último, la variable *Age* mantiene el VIF mas pequeño, consistente con su nula o débil correlación con el resto de las variables.

Buscamos ajustar un modelo eliminando algunas de las variables de grupos correlacionados. Primero nos enfocamos en eliminar la multicolinealidad mas fuerte con las variables de masa corporal. Como resultado obtenemos.

Table 5: Nuevos VIFs

Variable	mod1	mod2	mod3	mod4	mod5	mod6	mod7
Age	1.114160	1.113816	1.105818	1.040059	1.059029	1.111241	1.031691
Height	NA	1.330986	10.981185	1.021794	NA	NA	NA
Weight	2.159814	NA	11.201779	NA	1.042320	NA	NA
BMI	2.270898	1.427554	NA	NA	NA	1.095929	NA
Duration	9.687023	9.688465	9.690649	9.673478	9.668623	9.672376	9.667484
Heart_Rate	4.084640	4.087425	4.082288	4.076697	4.082154	4.072684	4.038460
Body_Temp	5.782853	5.784028	5.773272	5.762879	5.769906	5.782254	5.746476

Lo principal que podemos notar es que la multicolinealidad de los otros grupos de variables no fue afectada al remover estas variables. Además, quitando solo una nos basta para corregir multicolinealidad (excepto para el modelo 3). Reducimos el modelo eliminando *Height*, *Weight* y *BMI*, resultando en el AIC mas bajo.

Table 6: Nuevos VIFs

Variable	mod1	mod2	mod3	mod4	mod5	mod6
Age	1.012410	1.028119	1.002938	1.01082	1.002756	1.001491
Duration	NA	5.597107	3.965120	NA	NA	1.001491
Heart_Rate	2.338116	NA	3.970127	NA	1.002756	NA
Body_Temp	2.356918	5.649242	NA	1.01082	NA	NA

A excepción del modelo 2, basta quitar una sola variable para eliminar multicolinealidad. El modelo escogido será justificado en la siguiente sección ya que los supuestos del modelo son afectados fuertemente dependiendo de la combinación de estas tres variables específicamente.

3.3. Análisis de residuos

Haciendo prueba y error con cada uno de los modelos se encontró cuestiones muy interesantes sobre la relación entre *Duration*, *Heart_Rate* y *Body_Temp* y el cumplimiento de los supuestos.

Primero que nada, para cada una de las combinaciones se cumplía el supuesto de no autocorrelación al no rechazarse la prueba de Durbin-Watson mostrada mas adelante.

Sin embargo, lo curioso empieza cuando un modelo que solo incluya *Body_Temp* como parte del grupo de variables era la única forma de mantener varianza constante (homocedasticidad). Pero anulaba la normalidad de los residuos teniendo p-valores muy cercanos a cero en las pruebas de normalidad que se mencionarán mas adelante.

Por último, la mejor combinación se encontró eliminando *Duration* y dejando las otras dos variables. Esto no solo logro cumplir los supuestos de normalidad y no autocorrelación. Si no con unos p-valores cercanos a 1 en ambos casos. No importaba si se removian o añadian otras valores fuera de este grupo (*BMI* o *Gender*, por ejemplo). Mientras *Duration* no esté en el modelo, no podíamos negar normalidad ni autocorrelación. El problema era la homocedasticidad. Esta era brutalmente rechazada. Una vez que se notó que *Age*, en cierto punto afectaba la homocedasticidad de forma leve se optó por removerla completamente. Una vez que se cumplían todos los supuestos, se encontró una mejora todavía mayor al elevar al cuadrado tanto *Heart_Rate* como *Body_Temp* y una mejora todavía mayor incluyendo *BMI* (con *Height* o *Weight* se rechazaba homocedasticidad o tenían p-valores muy cercanos al nivel de significancia de 5%).

Ajustando el modelo se obtienen las siguientes características.

Table 7: Resumen del nuevo modelo

	Estimate	Std..Error	t.value	Pr...t..
(Intercept)	-681.159455	52.139856	-13.064084	0.000000
BMI	1.167666	0.906367	1.288292	0.199163
I(Heart_Rate^2)	0.021835	0.001181	18.482434	0.000000
I(Body_Temp^2)	0.337893	0.033664	10.037142	0.000000

- Multiple R-squared: 0.8941
- Adjusted R-squared: 0.8924
- P-valor conjunto: 0

Normalidad. Se evalúa si los residuales siguen una distribución aproximadamente normal. Mediante un QQ-plot, un histograma de frecuencias y un boxplot, para una interpretación visual. Se usan las pruebas de normalidad de Lilliefors, Cramér-von Mises, Anderson-Darling y Shapiro-Wilk.




Table 8: Pruebas de normalidad

Test	p_value
Lilliefors	0.8326
Cramér-von Mises	0.8743
Anderson-Darling	0.9102
Shapiro-Wilk	0.8511

Visualmente, todo se ve excelente. En cuanto a las pruebas, absolutamente no hay forma de rechazar la hipótesis de normalidad. Los errores siguen una distribución normal.

Homocedasticidad. Se muestra el gráfico de dispersión de residuales contra valores ajustados, así como las pruebas formales de homocedasticidad.




Table 9: Pruebas de homocedasticidad

	Test	p_values
BP	Breusch-Pagan	0.1688
	NCV	0.1824

Visualmente, no podríamos decir que tengamos una dispersión uniforme de los puntos. Mas bien, se ve una relación lineal en los residuales con los valores ajustados menores a cero, esto nos causa cierto grado de confusión especialmente por que no esperamos una cantidad negativa de calorías quemadas. Además, errores positivos se observan mas en los extremos de la distribución de las calorías, indicando una subestimación para valores muy grandes o pequeños en la quema de calorías. Por otro lado, en los valores centrales de la distribución se observa sobreestimación en las calorías quemadas. Esto podría deberse a que hay muchas observaciones cuya cantidad de calorías es muy cercana a cero. Esto podría ser problemático ya que es como si estuvieramos mediando la quema de calorías en gente que no hizo ejercicio o tuvo una rutina extremadamente corta (menor a 3 minutos). Aún así, por las pruebas de homocedasticidad no podemos rechazar que se tenga varianza constante en el modelo.

No autocorrelación. Finalmente, se evalúa la presencia de autocorrelación en los residuales mediante la prueba correspondiente.

Table 10: Prueba de no autocorrelación

Test	p_value
Durbin-Watson	0.8793767

Podemos observar que no podemos rechazar la autocorrelación de los errores residuales obteniendo un p-valor muy alto.

Este modelo nos permitió medir el gasto calórico por medio del índice de masa corporal, la frecuencia cardiaca y la temperatura corporal a la hora del ejercicio.

3.4. Valores influyentes




Table 11: Valores influyentes

	StudRes	Hat	CookD
1	3.30058	0.03732	0.10051
4	2.73086	0.02232	0.04121
75	-0.02119	0.08198	0.00001
76	2.51272	0.06569	0.10805

De las 200 observaciones tenemos 4 valores que podrían influir en nuestro modelo. La observación 1 y 76 son las que mayor influencia tienen en el modelo, son las observaciones con mayor distancia de Cook y leverage. La observación 4 tiene una distancia de Cook moderada. Lo cual podría indicar un valor borderline, es decir, un valor con influencia moderada. Por otro lado, la observación 75 no se considera influyente por su baja distancia de Cook (cerca a cero). Sin embargo, esta resalta por su alto leverage. Lo cual indica que la observación se encuentra en algún punto extremo o raro en sentido de las variables explicativas, pero explica la variable respuesta consistentemente con el modelo. Si observamos a estas 4 observaciones en la tabla podemos ver

Table 12: Observaciones influyentes

	Calories	Gender	Age	Height	Weight	BMI	Duration	Heart_Rate	Body_Temp
1	235	male	71	193	100	26.84636	29	104	41.5
4	254	male	72	178	80	25.24934	28	113	41.1
75	234	female	55	162	57	21.71925	28	122	40.9
76	3	male	46	179	84	26.21641	1	78	37.3

Vemos que la observación 1 y 4 tiene perfiles muy similares, con la mayor diferencia siendo el peso y la altura de la persona 1, es muy alta. Como el índice de masa corporal es directamente una relación entre el peso y la altura es posible que el modelo no capte bien estas diferencias (recordando que solo se incluye el BMI en el modelo) ya que ambas personas tienen un índice de masa corporal similar y a su vez causando una mala estimación de las calorías para esta persona en específico.

La observación 76 mantiene un perfil físico normal, pero con una un grado mínimo de esfuerzo físico (1 minuto de ejercicio) resultando en un gasto calórico muy pequeño. Lo cual podría sustentarse como una observación no comparable ya que se mide el gasto calórico por actividad física y esta persona no la realizó correctamente. Se considera como el valor mas problemático del modelo.

Por último, la observación 75 tenía un alto nivel de leverage lo que podría indicar una combinación poco común de variables pero sigue la tendencia del modelo. Por lo que se considera un punto raro, pero bien explicado.

4. Conclusiones

Los modelos finalistas fueron:

- Simple: Raíz cuadrada del gasto calórico explicado a través de la duración.
- Múltiple: Gasto calórico explicado por el BMI, el cuadrado de la frecuencia cardiaca y el cuadrado de la temperatura corporal.

En términos de ajuste, el modelo simple logra explicar un 95.1% de la raíz del gasto calórico, mientras que el modelo múltiple explica entre un 89.24% y un 89.41% del gasto calórico. Notemos que el coeficiente de determinación ajustado es muy cercano al coeficiente de determinación “simple”, por lo que la penalización por incluir múltiples variables es mínima.

El análisis de residuales no se puede realizar de manera directa, ya que el gasto calórico no se encuentra en la misma escala en ambos modelos, mientras que en el modelo simple, los residuales se explican en términos de la raíz cuadrada, los residuales del modelo múltiple están en su escala original.

Sin embargo, recordemos que los residuales del modelo simple fueron bastante buenos, ya que tenían muy poca variabilidad respecto de la unidad de medida, por otro lado, el modelo múltiple también tiene excelentes residuales, con un 50% de los residuos siendo cercanos a cero, residuo mínimo de -50.86 calorías, máximo de 66.70 calorías y un error residual estándar de 21.11 calorías, este modelo también presenta una variabilidad mínima.

En términos de significancia estadística, el modelo simple tiene una alta significancia en los coeficientes estimados, con p-valores de prácticamente cero, el modelo múltiple presenta el mismo resultado, exceptuando el coeficiente estimado para el BMI, que obtuvo un p-valor de 0.199, haciéndolo no significativo, no obstante, la prueba F del modelo múltiple obtiene un valor de prácticamente cero, por lo que el modelo múltiple en su conjunto es significativo.

En términos de supuestos cumplidos y considerando una confianza $\alpha = 0.05$, el modelo simple presenta problemas de homocedasticidad y normalidad, debido a las observaciones que se tienen cuando se aumenta la duración de la rutina, que comienzan a ser cada vez más volátiles, en cambio, el modelo múltiple cumple con todos los supuestos, lo que lo hace estadísticamente válido.

Finalmente, debe hacerse la observación que los criterios de AIC y BIC no fueron considerados, pues el gasto calórico se encuentra en diferente escala, volviendo los modelos no comparables bajo estos criterios.