

Análisis de Regresión: Gasto Calórico

Nicolás de Silva Nacenta, Israel Rodríguez Donato, Andrés Manuel Roldán Navarro

29 de mayo de 2026

1. Introducción

1.1. Contexto

La regresión lineal es un modelo que permite construir una relación lineal entre una variable “dependiente” y un conjunto de variables “independientes”. Esta relación permite explicar el comportamiento de la variable “dependiente” y predecir valores nuevos que podría tomar.

1.2. Objetivo general

Este proyecto tiene por objetivo ajustar modelos de regresión lineal que expliquen el número de calorías quemadas en función de variables de interés, así como evaluar el ajuste de estos modelos, que tan bien cumplen los supuestos de la regresión y la viabilidad de los modelos que se propongan.

1.3. Objetivos específicos

- Ajustar un modelo de regresión lineal simple.
- Ajustar un modelo de regresión lineal múltiple.
- Comparar ambos modelos.

2. Descripción de los datos

2.1. Variables

- Calories: Calorías
- Gender: Género
- Age: Edad
- Height: Altura (cm)
- Weight: Peso (Kg)
- BMI: Índice de masa corporal ($\frac{Kg}{m^2}$)
- Duration: Duración de actividad física (min)
- Heart_Rate: Frecuencia cardíaca (lpm)
- Body_Temp: Temperatura corporal (C°)

2.2. Carga de datos y visualización de la base de datos

Table 1: 10 observaciones de la base

Calories	Gender	Age	Height	Weight	BMI	Duration	Heart_Rate	Body_Temp
235	male	71	193	100	26.85	29	104	41.5
43	male	69	186	86	24.86	8	89	39.8
58	female	44	172	75	25.35	12	93	40.0

Calories	Gender	Age	Height	Weight	BMI	Duration	Heart_Rate	Body_Temp
254	male	72	178	80	25.25	28	113	41.1
21	female	39	179	76	23.72	6	82	39.4
13	female	34	165	61	22.41	3	89	38.1
154	male	62	185	91	26.59	24	97	40.6
16	male	25	193	99	26.58	4	91	38.9
37	female	41	177	76	24.26	10	83	39.8
158	female	32	179	76	23.72	29	101	41.0


3. Análisis descriptivo de datos

3.1. Estadísticos descriptivos

Table 2: Estadísticos descriptivos


	Media	Mediana	Moda	Varianza	Desviacion_Estandar
Calories	90.47	85.00	11.00	4143.61	64.37
Age	41.16	38.00	25.00	257.75	16.05
Height	173.85	174.00	179.00	177.87	13.34
Weight	74.33	73.00	57.00	210.13	14.50
BMI	24.32	24.37	23.72	2.77	1.66
Duration	15.58	17.00	6.00	74.35	8.62
Heart_Rate	95.79	97.00	101.00	99.35	9.97
Body_Temp	39.99	40.30	40.60	0.71	0.85

3.2. Visualización de variables




Matriz de correlación:

Hombres



Mujeres



Se pueden observar tres grupos de variables correlacionadas entre si para ambos género. Consisten en:

- Grupo 1: *Calories, Duration, Heart_Rate, Body_Temp*
- Grupo 2: *Height, Weight, BMI*
- Grupo 3: *Age*

Se puede ver que la edad no esta correlacionada con ninguna de las otras variables. Podria no ser significativa para la quema de calorías. La altura, peso e índice de masa corporal son caracateristicas físicas de la persona en cuestión, además el índice de masa corporal es directamente calculada usando las otras dos variables. Por último, la duración, frecuencia cardíaca y temperatura corporal son consecuencia del ejercicio en cuestión lo cual nos lleva a pensar que son los que mas afectan a la quema de calorías.

Analizando las matrices notamos que entre ambos géneros no existe gran diferencia en la correlación lo cual podría explicar que ningún género presenta ventaja sobre el otro a la hora de la quema de calorías.

4. Modelo de Regresión Lineal Simple


El modelo de regresión lineal simple construye la relación entre la variable dependiente y una sola variable independiente.


4.1. Selección de variable explicativa

Al realizar la rutina de ejercicio, el gasto calorico podría ser explicado por alguna de las siguientes variables numéricas, seleccionadas por tener una alta correlación con el gasto calórico: * *Duration*: tiene sentido pensar que mientras más tiempo se haya hecho ejercicio, mayo será el gasto calórico. * *Heart_Rate*: el número de latidos por minuto puede funcionar como una métrica del esfuerzo realizado por el individuo durante la rutina, esperaríamos que mayor esfuerzo, mayor gasto calorico. * *Body_Temp*: al igual que el número de latidos, una alta temperatura corporal indicaría un mayor gasto calorico, debido al esfuerzo realizado.


4.2. Ajuste del modelo

Para sustentar nuestra intuición, graficaremos estos modelos propuestos:





Gasto Calórico ~ Temperatura Corporal



4.3. Evaluación del modelo

Visualmente, cada uno de los modelos presenta un buen ajuste a los datos, sin embargo, vamos a estimar los coeficientes y revisar su significancia estadística, así como su coeficiente de ajuste:

```
##
## Call:
## lm(formula = Calories ~ Duration, data = calories)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -65.800 -10.854  -0.312   10.680   74.537
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -21.1772     2.6489  -7.995 1.06e-13 ***
## Duration      7.1657     0.1488  48.141 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.1 on 198 degrees of freedom
## Multiple R-squared:  0.9213, Adjusted R-squared:  0.9209
## F-statistic: 2318 on 1 and 198 DF, p-value: < 2.2e-16
##
## Call:
## lm(formula = Calories ~ Heart_Rate, data = calories)
```

```
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -75.135 -16.211   2.262  16.045  96.205
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -473.4245    18.1755  -26.05  <2e-16 ***
## Heart_Rate    5.8867     0.1887   31.19  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 26.54 on 198 degrees of freedom
## Multiple R-squared:  0.8309, Adjusted R-squared:  0.83
## F-statistic: 972.9 on 1 and 198 DF,  p-value: < 2.2e-16
##
## Call:
## lm(formula = Calories ~ Body_Temp, data = calories)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -62.608 -27.667  -5.437  19.689  93.278
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2450.092    119.283  -20.54  <2e-16 ***
## Body_Temp     63.523     2.982    21.30  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 35.57 on 198 degrees of freedom
## Multiple R-squared:  0.6962, Adjusted R-squared:  0.6947
## F-statistic: 453.8 on 1 and 198 DF,  p-value: < 2.2e-16
```

Podemos notar que los 3 modelos presentan coeficientes estadísticamente significativos, donde el modelo basado en duración tiene un ajuste del 92.13%, el de frecuencia un ajuste del 83.09% y el de temperatura corporal un ajuste del 69.62%.

Quisieramos quedarnos con el primer modelo, ya que tiene coeficientes estadísticamente significativos y logra explicar en un 92.13% la variabilidad del gasto calórico, sin embargo, el coeficiente de ajuste no es suficiente por si mismo para evaluar a un modelo, por lo que el siguiente paso lógico es evaluar si cada modelo cumple los supuestos

4.4. Supuestos del modelo

```
## [1] "Modelo Basado en Duración"
## $shapiro_wilk
##
## Shapiro-Wilk normality test
##
## data:  residuos
## W = 0.97923, p-value = 0.004632
##
##
```



```

## $ncv_homocedasticidad
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 39.32593, Df = 1, p = 3.5865e-10
##
## $durbin_watson
##
## Durbin-Watson test
##
## data: modelo
## DW = 1.799, p-value = 0.07685
## alternative hypothesis: true autocorrelation is greater than 0
##
##
## $breusch_godfrey
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: modelo
## LM test = 1.3338, df = 1, p-value = 0.2481
##
## [1] "Modelo Basado en Frecuencia Cardíaca"
##
## $shapiro_wilk
##
## Shapiro-Wilk normality test
##
## data: residuos
## W = 0.9866, p-value = 0.05553
##
##
## $ncv_homocedasticidad
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 1.827975, Df = 1, p = 0.17637
##
## $durbin_watson
##
## Durbin-Watson test
##
## data: modelo
## DW = 2.2653, p-value = 0.9705
## alternative hypothesis: true autocorrelation is greater than 0
##
##
## $breusch_godfrey
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: modelo
## LM test = 5.5024, df = 1, p-value = 0.01899
##
## [1] "Modelo Basado en Temperatura Corporal"
##
## $shapiro_wilk
##

```

```
## Shapiro-Wilk normality test
##
## data:  residuos
## W = 0.95188, p-value = 2.876e-06
##
##
## $ncv_homocedasticidad
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 1.398754, Df = 1, p = 0.23693
##
## $durbin_watson
##
## Durbin-Watson test
##
## data:  modelo
## DW = 1.9058, p-value = 0.2521
## alternative hypothesis: true autocorrelation is greater than 0
##
##
## $breusch_godfrey
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data:  modelo
## LM test = 0.33133, df = 1, p-value = 0.5649
```

En general, podemos notar que ningún modelo sale bien librado, los principales problemas están relacionados con homocedasticidad y normalidad de los errores. Tiene sentido, pues si observamos nuestros gráficos, podemos notar que los datos, a pesar de tener un coeficiente de ajuste alto, no se adecúan a la forma de una línea recta.

Para solucionar este problema, podemos intentar una transformación BoxCox de los datos, buscando solucionar los problemas de homocedasticidad y normalidad, aunque, gráficamente, un modelo más adecuado sería un polinomio, particularmente uno de grado 2.

```
## lambda (Duration)    : 0.5
## lambda (Heart_Rate) : 0.6
## lambda (Body_Temp)   : 0.1
##
## Call:
## lm(formula = Cal_trans_dur ~ Duration, data = calories)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.1707 -0.9325 -0.0511  0.9130  5.5088
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.37266    0.24007   9.883  <2e-16 ***
## Duration     0.84322    0.01349  62.507  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```


## Residual standard error: 1.641 on 198 degrees of freedom
## Multiple R-squared:  0.9518, Adjusted R-squared:  0.9515
## F-statistic: 3907 on 1 and 198 DF,  p-value: < 2.2e-16


##
## Call:
## lm(formula = Cal_trans_hr ~ Heart_Rate, data = calories)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.1588  -2.2663   0.3085   2.7587  12.5509
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -77.95857     3.15356  -24.72  <2e-16 ***
## Heart_Rate   1.03698     0.03275   31.67  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.604 on 198 degrees of freedom
## Multiple R-squared:  0.8351, Adjusted R-squared:  0.8343
## F-statistic: 1003 on 1 and 198 DF,  p-value: < 2.2e-16


##
## Call:
## lm(formula = Cal_trans_bt ~ Body_Temp, data = calories)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.70263 -0.33924  0.01161  0.35177  1.38681
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -63.38434     1.72172  -36.81  <2e-16 ***
## Body_Temp    1.71367     0.04304   39.82  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5134 on 198 degrees of freedom
## Multiple R-squared:  0.889,  Adjusted R-squared:  0.8884
## F-statistic: 1585 on 1 and 198 DF,  p-value: < 2.2e-16

```

Una vez aplicada la transformación BoxCox, vamos a realizar una inspección visual.







Visualmente, el comportamiento ha mejorado mucho, así que toca reevaluar los supuestos

```
## [1] "Modelo Duración (BoxCox en Y)"
## $shapiro_wilk
##
## Shapiro-Wilk normality test
##
## data:  residuos
## W = 0.98618, p-value = 0.048
##
## $ncv_homocedasticidad
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 4.566497, Df = 1, p = 0.032603
##
## $durbin_watson
##
## Durbin-Watson test
##
## data:  modelo
## DW = 1.8305, p-value = 0.1146
## alternative hypothesis: true autocorrelation is greater than 0
##
## $breusch_godfrey
```

```

##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: modelo
## LM test = 1.1201, df = 1, p-value = 0.2899
## [1] "Modelo Frecuencia Cardíaca (BoxCox en Y)"
## $shapiro_wilk
##
## Shapiro-Wilk normality test
##
## data: residuos
## W = 0.98233, p-value = 0.01287
##
##
## $ncv_homocedasticidad
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 0.8658204, Df = 1, p = 0.35211
##
## $durbin_watson
##
## Durbin-Watson test
##
## data: modelo
## DW = 2.2554, p-value = 0.9654
## alternative hypothesis: true autocorrelation is greater than 0
##
##
## $breusch_godfrey
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: modelo
## LM test = 4.3135, df = 1, p-value = 0.03781
## [1] "Modelo Temperatura Corporal (BoxCox en Y)"
## $shapiro_wilk
##
## Shapiro-Wilk normality test
##
## data: residuos
## W = 0.99628, p-value = 0.9121
##
##
## $ncv_homocedasticidad
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 5.307276, Df = 1, p = 0.021237
##
## $durbin_watson
##
## Durbin-Watson test
##

```

```
## data:  modelo
## DW = 1.9495, p-value = 0.3603
## alternative hypothesis: true autocorrelation is greater than 0
##
##
## $breusch_godfrey
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data:  modelo
## LM test = 0.029225, df = 1, p-value = 0.8643
```

4.5. Intervalos de confianza (95 %)

4.6. Intervalos para respuesta media y predicción

5. Modelo de Regresión Lineal Múltiple

5.1. Selección de variables

Para una selección inicial definimos un modelo utilizando todas las variables y mediante un proceso de stepwise AIC hacia atras, obtenemos un AIC inicial de 965.38. Luego, definiendo un modelo nulo, mediante stepwise AIC hacia adelante, obtenemos un AIC inicial de 1666.86.

En nuestro caso el modelo con el AIC mas bajo resulta ser ajustando el modelo explicando las calorías utilizando todas las variables numéricas y eliminando el género. Obteniendo un valor AIC de 963.42. Esto podria ser ya que como vimos en las matrices de correlación que el género no influye fuertemente en la quema de calorías.

5.2. Ajuste del modelo

Table 3: Resumen del modelo

	Estimate	Std..Error	t.value	Pr...t..
(Intercept)	806.651932	150.044788	5.376074	0.000000
Age	0.574970	0.050832	11.311081	0.000000
Height	-2.259628	0.671005	-3.367527	0.000916
Weight	2.763605	0.786413	3.514190	0.000550
BMI	-8.850941	2.444765	-3.620365	0.000376
Duration	6.569909	0.279029	23.545636	0.000000
Heart_Rate	1.910338	0.157009	12.167066	0.000000
Body_Temp	-15.564089	2.204011	-7.061712	0.000000

Adicionalmente obtenemos estas características:

- Multiple R-squared: 0.9723
- Adjusted R-squared: 0.9713
- p-valor conjunto: $< 2.2 \times 10^{-16}$

5.3. Evaluación de multicolinealidad del modelo

Table 4: Valores de Inflación de la Varianza (VIF)

	VIF
Age	1.115079
Height	134.082375
Weight	217.577707
BMI	27.728096
Duration	9.691175
Heart_Rate	4.100656
Body_Temp	5.814618

Podemos ver que el modelo tiene multicolinealidad fuerte en las variables *Height*, *Weight* y *BMI*, donde directamente el índice de masa corporal es una relación entre la altura y el peso lo cual explica la alta correlación entre este grupo de variables. Por otro lado, variables como *Duration*, *Heart_Rate* y *Body_Temp* presentan multicolinealidad moderada. Igualmente por la matriz de correlación observamos una correlación fuerte entre este otro grupo de variables. Por último, la variable *Age* mantiene el VIF mas pequeño, consistente con su nula o débil correlación con el resto de las variables.

Buscamos ajustar un nuevo modelo mediante la eliminación de algunas de las variables de grupos correlacionados. Como primer intento eliminaremos una variable del grupo de duración, frecuencia cardíaca y temperatura corporal. Como resultado obtenemos los nuevos VIFs.

Table 5: Nuevos VIFs

Variable	Modelo_1	Modelo_2	Modelo_3
Age	1.093	1.113	1.078
Height	134.024	133.558	133.349
Weight	217.516	216.875	216.433
BMI	27.726	27.603	27.53
Duration	...	5.665	4.058
Heart_Rate	2.397	...	4.045
Body_Temp	2.434	5.736	...

Obtenemos los siguientes AICs:

- Modelo 1: 1802.54
- Modelo 2: 1645.309
- Modelo 3: 1577.17

El modelo 3 es el que menor AIC tiene, sin embargo por cuestiones que se discutiran en la siguiente sección escogemos el modelo que excluye la variable *Duration* (Modelo 1). Ahora nos enfocamos en el otro grupo de variables relacionados con el índice de masa corporal.

Table 6: Nuevos VIFs

Variable	Modelo_1	Modelo_2	Modelo_3	Modelo_4	Modelo_5	Modelo_6	Modelo_7
Age	1.092	1.092	1.084	1.021	1.04	1.09	1.012
Height	...	1.328	10.956	1.021	...	...	...
Weight	2.156	...	11.181	...	1.042	...	...
BMI	2.266	1.425	...	...	...	1.095	...
Heart_Rate	2.387	2.388	2.381	2.364	2.376	2.384	2.338
Body_Temp	2.387	2.392	2.387	2.387	2.386	2.378	2.356

AICs de los modelos:

- Modelo 1: 1804.49
- Modelo 2: 1804.60
- Modelo 3: 1804.36
- Modelo 4: 1802.60
- Modelo 5: 1802.52
- Modelo 6: 1802.63
- Modelo 7: 1800.64

A excepción del modelo 3, ya ninguna presenta multicolinealidad. Pero el modelo 7 consiste del AIC mas bajo en comparación con los demás nos indica que el mejor modelo que mejor explica la quema de calorías es aquel excluyendo las variables: *Duration*, *Height*, *Weight* y *BMI*. Ajustando el modelo obtenemos los siguientes resultados.

Table 7: Resumen del nuevo modelo

	Estimate	Std..Error	t.value	Pr. . . t..
(Intercept)	-1321.758485	94.544943	-13.980213	0.0e+00
Age	0.404388	0.095493	4.234729	3.5e-05
Heart_Rate	4.270580	0.233742	18.270493	0.0e+00
Body_Temp	24.666251	2.766503	8.916038	0.0e+00

[1] 21.3315

- Multiple R-squared: 0.8902
- Adjusted R-squared: 0.8885
- P-valor conjunto: $< 2.2 \times 10^{-16}$

5.4. Análisis de residuos

En la sección anterior se mencionó que se utilizaba el modelo que excluía la variable *Duration* con todo y que tenía el mayor AIC de los tres modelos. La razón es por los supuestos. Era el único modelo que cumple con los supuestos de normalidad y autocorrelación en los residuos. Sin embargo, todavía tenemos heterocedasticidad.

Normalidad. Se evalúa si los residuales siguen una distribución aproximadamente normal. Mediante un QQ-plot, un histograma de frecuencias y un boxplot, para una interpretación visual. Se usan las pruebas de normalidad de Lilliefors, Cramér-von Mises, Anderson-Darling y Shapiro-Wilk.




Table 8: Pruebas de normalidad

Test	p_value
Lilliefors	0.6172
Cramér-von Mises	0.5355
Anderson-Darling	0.6631
Shapiro-Wilk	0.9409

Homocedasticidad. Se muestra el gráfico de dispersión de residuales contra valores ajustados, así como las pruebas formales de homocedasticidad.




Table 9: Pruebas de homocedasticidad

	Test	p_values
BP	Breusch-Pagan	0.0001
	NCV	0.3414

No correlación. Finalmente, se evalúa la presencia de autocorrelación en los residuales mediante la prueba correspondiente.

Table 10: Prueba de autocorrelación

Test	p_value
Durbin-Watson	0.9154723

6. Comparación de modelos

7. Conclusiones